

# Análisis de señales ECG y detección de arritmias - Análisis espectral

Bioseñales y sistemas

Allisson Rojas Niebles  
*Universidad de Antioquia*  
Medellín, Colombia  
allisson.rojas@udea.edu.co

Fabio Velez Osorio  
*Universidad de Antioquia*  
Medellín, Colombia  
fabio.velezo@udea.edu.co

## Resumen

Las arritmias cardíacas son detectadas comúnmente a través del análisis de señales electrocardiográficas (ECG). Este trabajo presenta un enfoque combinado de procesamiento de señales y análisis estadístico para la identificación y caracterización de arritmias. Se aplicaron la Transformada discreta de Fourier (DFT) para el análisis espectral, la transformada discreta del coseno (DCT) para la compresión y reducción de características, y los coeficientes cepstrales en las frecuencias de Mel (MFCC). Además, se utilizó análisis descriptivo para explorar variables encontradas en las transformadas, complementado con pruebas de hipótesis para determinar diferencias significativas entre arritmia. Los resultados demuestran que la integración de estas técnicas permite distinguir de manera efectiva patrones asociados a distintas arritmias.

**Palabras clave:** ECG, arritmia, DFT, DCT, MFCC, análisis descriptivo, pruebas de hipótesis, procesamiento de señales.

## I. Introducción.

Las arritmias es una de las condiciones que afectan la frecuencia o el ritmo del latido del corazón. El diagnóstico oportuno de estas alteraciones es fundamental para reducir los riesgos asociados y mejorar el pronóstico de los pacientes. Considerando esto, el electrocardiograma (ECG) se ha establecido como la principal herramienta diagnóstica para la detección y caracterización de arritmias, ya que permite registrar de forma no invasiva la actividad eléctrica del corazón y analizar patrones característicos de diferentes patologías[1].

En este contexto, la transformada discreta de Fourier (DFT) se emplea para analizar el contenido espectral de la señal ECG, permitiendo identificar frecuencias dominantes que pueden asociarse con ritmos cardíacos irregulares. La transformada discreta del coseno (DCT), por su parte, ofrece una

representación compacta de la señal que facilita la compresión de información y la extracción de características relevantes para la clasificación de ritmos. Asimismo, los coeficientes cepstrales en las frecuencias de Mel (MFCC), han demostrado ser útiles en el análisis de señales ECG al capturar la forma espectral de los latidos, lo cual puede ser explotado en algoritmos de detección automática de arritmias[2].

El análisis estadístico complementa las transformaciones aplicadas a las señales ECG, permitiendo mediante estadísticas descriptivas y pruebas de hipótesis identificar y validar diferencias significativas entre sujetos, especialmente en los valores encontrados de las transformadas[3][4].

El presente trabajo tiene como objetivo realizar la extracción de características espectrales a partir de señales ECG procesadas, buscando identificar atributos de diferenciación que permitan distinguir entre diversos tipos de arritmia por medio de un análisis estadístico y visual.

## II. Metodología.

El análisis de arritmias cardíacas mediante el procesamiento de señales ECG. Se utilizan técnicas como la Transformada Discreta de Fourier (FDT), la Transformada Discreta del Coseno (DCT) y los coeficientes cepstrales en las frecuencias de Mel (MFCC) para extraer características relevantes. Con el objetivo de extraer características relevantes que permitan diferenciar distintos tipos de arritmias con análisis estadísticos aplicada a grupos.

### A. Transformada Discreta de Fourier (FDT)

Convierte una señal en el dominio del tiempo a una representación en el dominio de la frecuencia, permitiendo analizar sus componentes frecuenciales, su ecuación está dada por:

$$X(k) = \sum_{n=0}^{N-1} x(n) \cdot e^{-i2\pi kn/N}$$

$x(n)$ : Señal de entrada en el tiempo  
 $N$ : Número total de muestras  
 $X(k)$ : Componente en la frecuencia  $k$   
 $i$ : Unidad imaginaria

Teniendo el vector  $x(n)$ , que representa los valores muestreados de la señal en el dominio del tiempo, ver Tabla 1, se obtiene el vector  $X(k)$ , el cual contiene los coeficientes espectrales en el dominio de la frecuencia, ver Tabla 1. Cada valor de  $X(k)$  esta compuesto por una parte real y una parte imaginaria, que describen la amplitud y la fase de cada componente de frecuencia[5]

timestamp	ecg_signal	k	parte_real	parte_imaginaria
0	-24.839000	0	1776.546189	0.000000
1	-21.031000	1	-1670.455303	-1684.286322
2	-17.969000	2	414.085315	2939.161913
3	-15.853000	3	616.732199	271.615552
4	-14.703000	4	-3520.349047	-1891.284342
5	-14.478000	5	76.753289	1506.606233

(a)

(b)

**Tabla 1.** Primeros valores de los vectores en Python. (a) Vector  $x(n)$  en el tiempo. (b) Vector  $X(k)$  de su parte real e imaginaria.

Características del vector  $X(k)$  a encontrar:

- Espectro de magnitud

Su ecuación es:

$$|X[k]| = \sqrt{Re[X(k)]^2 + Im[X(k)]^2}$$

Lo que resultará en un vector de magnitudes de los coeficientes de la señal, ver figura 1.

k	magnitud
0	1776.546189
1	2372.180712
2	2968.187898
3	673.894363
4	3996.224953
5	1508.560045

**Figura 1.** Primeros valores de magnitud de los coeficientes  $X(k)$  en Python.

- Espectro de fase

Como el vector  $X(k)$  contiene parte imaginaria, entonces la señal puede mostrar sus desfases.


$$\angle X(k) = \tan^{-1} \left( \frac{Im(X(k))}{Re(X(k))} \right)$$

Lo que resultará en un vector de magnitudes de los coeficientes de la señal, ver figura 2.

k	fase
0	0.000000
1	-2.352072
2	1.430832
3	0.414851
4	-2.648596
5	1.519896

**Figura 2.** Primeros valores de fase de los coeficientes  $X(k)$  en python.

Gráficamente se pueden ver en la figura 3.



(a)

(b)

**Figura 3.** Primeros diez valores del espectro en Python (a) Espectro de magnitud. (b) Espectro de fase.

- Potencia

El teorema de parseval, la potencia también puede calcularse desde los coeficientes de la DFT, con la siguiente ecuación:

$$P = \frac{1}{N} \sum_{n=0}^{N-1} |X(k)|^2$$

Esto significa que la energía (o potencia) total de la señal está distribuida entre las frecuencias representadas por  $X(k)$ .

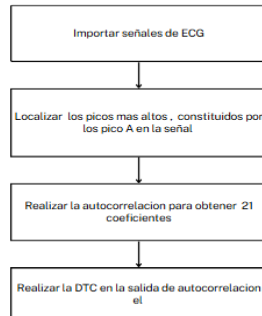
**B. Transformada Discreta del Coseno (DCT)**

Convierte una señal discreta del tiempo  $x(n)$  en una representación en términos de cosenos con diferentes frecuencias. no contiene partes imaginarias, solo partes reales, está dada por:

$$X(k) = \sum_{n=0}^{N-1} x(n) \cdot \cos\left(\frac{\pi}{N}\left(n + \frac{1}{2}\right)k\right)$$

$x(n)$ : Señal de entrada en el tiempo  
 $N$ : Número total de muestras  
 $X(k)$ : Coeficientes de la DCT  
 $k$ : Índice de frecuencia


Para las señales se realiza el paso a paso de esta transformada propuesto, ver Diagrama 1 [6], Esto con el fin de ver características importantes en los coeficientes.



**Diagrama 1.** Algoritmo para la extracción de coeficientes para la DCT.


Para el flujo se procesa de la siguiente manera:

1. Cargar las señales de las arritmias ya filtradas.
2. Detectar los picos R de la señal utilizando la librería Neurokit, ver figura 4, sus índices serán el vector detectado de los picos R.



**Figura 4.** Picos R detectados por neurokit en Python.


3. Se aplica autocorrelación al vector de picos R detectados y se extraen sus 21 primeros coeficientes, ver figura 5, ya que con este flujo queremos capturar información de patrones y periodicidades característica de la señal ECG.



**Figura 5.** Autocorrelación de 21 coeficientes de picos R detectados en Python.

4. Se aplica la DCT a los 21 coeficientes capturados de la autocorrelación, ver

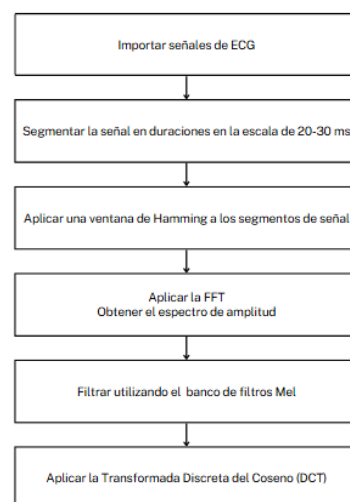
figura 6, eso nos da en frecuencia y ver los componentes más importantes, los que contienen más energía.



**Figura 6.** Magnitud DCT a los 21 coeficientes de correlación en Python.

### C. Coeficientes cepstrales en las frecuencias de Mel (MFCC) [a][b]

Convierten una señal de tiempo en un conjunto de coeficientes que representan las propiedades espectrales de la señal de una forma que se asemeja a cómo percibe la señal el oído humano ya que es comúnmente usado con señales de Voz. Esta metodología puede aplicarse a una señal ECG, ver Diagrama 2, permite resaltar componentes frecuenciales relevantes de las señales ECG, reduce la dimensionalidad de entrada. y puede capturar cómo cambia el contenido frecuencial del ECG en el tiempo, lo cual puede ser útil para detectar arritmias, isquemias, o fibrilación auricular.




**Diagrama 2.** Algoritmo para la extracción de coeficientes MFCC.

Para el análisis se procede de la siguiente manera:

### 1. Segmentar la señal en duraciones en la escala de 20-30 ms

Se divide la señal en tramos cortos (ventanas) (por ejemplo 25 ms), Ver figura 8, la señal cambia en el tiempo y queremos analizar pequeñas porciones quasi-estacionarias.




**Figura 8.** Ventana de 25ms de la señal ECG, se muestran 12 segmentos.

### 2. Aplicar una ventana de Hamming a los segmentos de señal. Se usa en cada tramo para suavizar los bordes, reducir los cambios reduce saltos drásticos en la amplitud de la señal, ver Figura 9, minimiza la discontinuidad de bordes

$$W_n = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right), 0 \leq n < N$$

- señal segmentada:

$$X_w[n] = x[n] - w[n]$$



**Figura 9.** Aplicando ventana de Hamming, primeros 5 segmentos de la señal ECG.

### 3. Aplicar la FFT


Se calcula el espectro de magnitud de cada frame usando FFT.

su ecuación está dada por:


$$X[k] = \sum_{n=0}^{N-1} X_w[n] * e^{-j2\pi} - w[n]$$

que permite obtener el espectro de amplitud de cada tramo, Ver figura 10 (a).

Se calcula el espectro de potencia para cada tramo, ver Figura 10 (b).



(a)



(b)

**Figura 10.** (a) Espectro de magnitud de la FFT. (b) Potencia de la FFT

### 4. Banco de filtros Mel

Es un banco de filtros tipo pasa banda triangular (ej. 20-40 filtros) distribuidos no linealmente en la escala Mel. Cada filtro  $H_m[k]$  suma la energía en su banda:


Conversión de frecuencia a escala Mel:

$$f = 2595 \log_{10}\left(1 + \frac{f}{700}\right)$$

Los filtros triangulares se aplican al espectro de potencia  $P[k]$ , y se suman las energías, Ver figura 11.

$$E[m] = \sum_{k=0}^{N/2} P[k] * H_m[k]$$


$H_m[k]$ : respuesta del filtro en la posición m.



**Figura 11.** Espectrograma con el banco de filtros Mel.

### 5. Aplicar la Transformada Discreta del Coseno (DCT)

Encontramos los coeficientes cepstrales de mel con la transformada del coseno, ver Figura 12 y sus coeficientes, Ver figura 13.



**Figura 12.** Representación de coeficientes MFCC.

Vector de características: [-1.6728579 20.786219 8.290584 3.9357152 0.2527024 -2.864  
0.10074618 3.2998207 2.1044195 1.7623217 1.612055 2.3455617  
2.575481 9.88251 7.6180666 2.2823623 1.8096458 2.8250477  
2.9442706 3.5169132 2.84843 1.6227499 2.3418639 1.8533921  
1.6683476 1.713267 ]

**Figura 13.** Vector de características MFCC

#### D. Análisis estadístico

Con el objetivo de comparar las características extraídas mediante la FDT, DCT Y MFCC a partir de las señales ECG, se realizó el siguiente procedimiento:

##### 1. Comparación Gráfica descriptiva entre los grupos.

Se emplean técnicas para contrastar los resultados aplicados de las metodologías A, B y C a los diferentes grupos de arritmias, con diagramas de caja, diagrama de barras, lo cual permite ver diferencias de los grupos, lo cual permitirá ver, cuál de las metodologías aplicadas ofrecen mayor poder discriminativo.

##### 2. Pruebas de hipótesis.

Validar estadísticamente las diferencias, validar la normalidad de los datos con la prueba de Shapiro-Wilk, prueba t de Student, prueba de Mann-Whitney.

Se las aplicamos al grupo de arritmias para ver si encontramos sus diferencias.

##### Prueba t de Student

- Hipótesis nula ( $H_0$ )

No hay diferencia significativa entre los vectores de características de los grupos de arritmias

- Hipótesis alternativa ( $H_1$ )

Sí hay diferencia significativa entre los vectores de características de los grupos.

##### Shapiro-Wilk

- $H_0$  (hipótesis nula): Las distribuciones en los dos grupos siguen una distribución normal.

- $H_1$  (hipótesis alternativa): Las distribuciones en los dos grupos no siguen una distribución normal.

##### prueba de Mann-Whitney

- Hipótesis nula ( $H_0$ )

No hay diferencia significativa de características de los grupos.


- Hipótesis alternativa ( $H_1$ )

Sí hay diferencia significativa entre los vectores de características de los grupos.

### III. Resultados

El presente estudio encontró con estos métodos de extracción de características aplicados a señales con arritmia, cada técnica fue desarrollada paso a paso siguiendo los lineamientos teóricos[6]. Posteriormente, se llevó a cabo un análisis y comparación de las características extraídas entre diferentes grupos utilizando métodos de estadística descriptiva y pruebas de hipótesis, con el objetivo de identificar cuáles métricas permiten tener una mejor discriminación entre clases.


#### Extracción de características usando la transformada discreta del coseno.



**Figura 14.** Comparación de coeficientes promedio DCT por arritmia.

Se puede observar en la Figura 14, que los primeros coeficientes en especial el coeficiente 0, de baja frecuencia tienen la mayor parte de la energía de la señal, con una disparidad notable entre clases. El coeficiente de la arritmia taquicardia supraventricular (SVT) muestra un valor mayor de manera notable en el primer coeficiente, esto indica una característica específica en su


representación espectral. Desde el tercer coeficiente en adelante, los valores tienden a estabilizarse en todas las arritmias cerca de cero para todos los coeficientes, lo que señala una menor importancia de los coeficientes de alta frecuencia en la diferenciación entre arritmias.



**Figura 15.** Potencia del promedio DCT por arritmia en Python.

Se puede observar en la Figura 15, la potencia del promedio de los coeficientes DCT para cada variedad de arritmia. Se observa que la arritmia SVT presenta la mayor potencia, en contraste al resto de las demás arritmias, esto indica una mayor concentración de energía en sus componentes más frecuentes. Las arritmias Fibrilación Auricular (AF) y Taquicardia Sinusal (ST) también presentan potencias un poco altas, mientras que las arritmias síncope del nodo sinusal (SA) y bradicardia sinusal (SB) muestran los valores más bajos.

### Extracción de características usando la transformada discreta de Fourier.

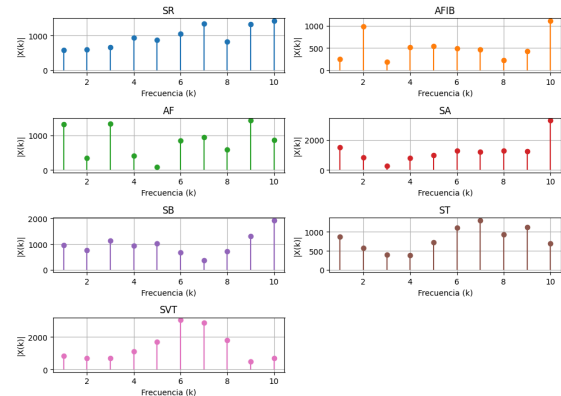


**Figura 16.** Magnitud promedio de la DFT por arritmia expresado por caja de bigotes en python.

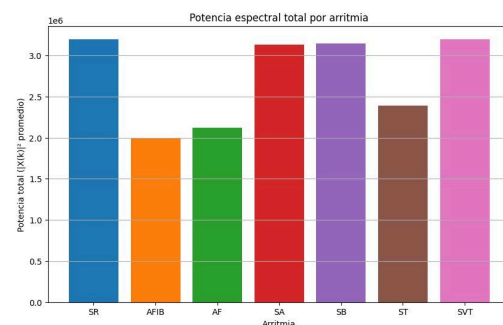
La Figura 16 muestra un diagrama de cajas y bigotes luego de aplicarle DFT. Se nota una gran variabilidad espectral en todas las arritmias, con muchos valores atípicos, especialmente en AF, SA y ST. Las clases SA y SB presentan las medianas más altas en comparación con SR y AFIB, lo que involucra diferencias en la distribución de dispersión de las magnitudes encontradas, esto nos permite ver la variabilidad de los datos en sus valores del espectro de magnitud, ver Figura 17, esto nos muestra la diferencia de magnitudes según las diferentes

arritmias y como va cambiando según las altas y bajas frecuencias.

Primeros 10 valores del espectro de magnitud (DFT) por arritmia



**Figura 17.** Espectro de magnitud en las arritmias en muestras de 10 valores en Python.



**Figura 18.** Potencia espectral total de las arritmias en Python.

Se observa que las clases SR, SA, SB y SVT presentan los valores más altos de potencia, cercanos o superiores a una escala de  $3 \times 10^3$ , lo que podría indicar una densidad energética más grande en sus componentes frecuenciales esto puede observarse en la figura 18. En cambio las clases AFIB y AF muestran menor potencia total, lo que podría reflejar una menor actividad espectral o mayor regularidad en la señal.

```
Potencia espectral (DFT) por arritmia:
SR: 3196580.4875
AFIB: 1999283.7794
AF: 2120502.4943
SA: 3131672.4783
SB: 3143617.9835
ST: 2387699.9134
SVT: 3198552.4283
```

**Figura 19.** Potencia espectral DFT

Los resultados de los valores, ver Figura 19, muestran que el ritmo sinusal (SR) y la taquicardia supraventricular (SVT) presentan las potencias espectrales mucho más altas, mientras que la

fibrilación auricular (AFIB) y la fibrilación auricular (AF) exhiben valores considerablemente menores. Estas diferencias reflejan cómo la distribución de energía en la señal varía según la arritmia, lo que puede ser útil para su caracterización y diferenciación en el dominio de la frecuencia. También comparando con la DCT las potencias tienden a ser parecidas en sus niveles de energía, esto nos muestra cómo se captura con las transformaciones sin perder esos valores de energía importantes para la señal[5].

### Extracción de características usando MFCC.

PROMEDIO DE PMCCs POR ARRITMIA						
arritmia	coef_1	coef_2	coef_3	coef_4	coef_5	coef_6 \
SR	-6.456958	9.605546	2.766483	1.190781	-0.685255	-4.956730e-07
AFIB	-6.931845	9.476730	2.798136	1.005308	-0.810508	-5.343570e-07
AF	-4.743255	9.466088	2.811822	1.176215	-0.694504	-1.875121e-07
SA	-7.375162	9.596002	2.781684	1.077691	-0.762667	-5.543989e-07
SB	-9.594099	9.641732	2.749336	0.883351	-0.878064	-2.330560e-06
ST	-3.469132	9.492192	2.828725	1.285259	-0.644801	2.685889e-07
SVT	-4.921762	8.988869	2.590556	1.277646	-0.545545	-1.281243e-07
arritmia	coef_7	coef_8	coef_9	coef_10		
SR	-0.743961	-0.606734	-2.408529	-1.521369		
AFIB	-0.652959	-0.512231	-2.418814	-1.500967		
AF	-0.737241	-0.599312	-2.423261	-1.499281		
SA	-0.687717	-0.549112	-2.413468	-1.519858		
SB	-0.603874	-0.450094	-2.402955	-1.527102		
ST	-0.773354	-0.654923	-2.428756	-1.503416		
SVT	-0.776476	-0.650993	-2.267498	-1.423697		

Figura 20. Captura de 10 coeficientes promedio de MFCC por arritmia en Python.

Se observa en la figura 20, que existen diferencias sutiles pero consistentes en los coeficientes entre clases, especialmente en los tres primeros coeficientes, que son los que contienen la mayor información de la señal, lo que podría reflejar patrones espectrales particulares asociados a estas arritmias y como tienden a un mismo valor. Las arritmias pueden no estar suficientemente diferenciadas en el dominio espectral. Esto sugiere que usar solo MFCCs podría no ser suficiente para clasificarlas con precisión, ver figura 21, y Figura 22, logrando ver cambios pequeños en sus promedios pero que no nos dejan ver sus diferencias claras en sus componentes de forma y ritmo[4].




Figura 21. Potencia del promedio DCT por arritmia en caja de bigotes en Python.




Figura 21. Potencia del promedio DCT por diagrama de barras en cada arritmia en Python.

Este procedimiento permitió obtener vectores de características que capturan tanto la distribución de energía como los cambios temporales de la señal, lo que es particularmente relevante en arritmias. Estos resultados reflejan que los MFCC no sólo capturan la cantidad de energía en la señal, sino cómo esta energía está distribuida a lo largo del tiempo y en distintas bandas frecuenciales logrando condensar patrones complejos en pocos coeficientes.

**Coefficiente 0:** Representa la energía logarítmica total, En valor más negativo que es (SB), este coeficiente indica una señal con menor energía espectral, lo cual está asociado a una actividad cardíaca más débil, regular o menos compleja. En las arritmias, esta característica permite diferenciar ritmos con mayor o menor variabilidad.

**Coefficiente 2:** Refleja la variación del contenido espectral en las bandas de frecuencia medias de la señal ECG. A diferencia del coeficiente 0, que resume la energía total, el coeficiente 2 capta cómo



cambia la forma del espectro en estas frecuencias intermedias. Un valor más alto de MFCC<sub>2</sub> puede indicar una mayor concentración de energía en bandas medias, lo cual puede estar relacionado con patrones cardíacos más activos o complejos, como los observados en arritmias tipo (ST) o (AF).

**Coefficiente 5:** Representa variaciones más finas en la estructura espectral de la señal ECG, particularmente en las bandas de frecuencia más altas dentro de la escala de Mel. Aunque su contribución energética es menor en comparación con los primeros coeficientes, MFCC<sub>5</sub> captura detalles sutiles asociados a transiciones rápidas o a irregularidades en la señal. Las arritmias variaciones en este coeficiente refleja alteraciones agudas o patrones de alta frecuencia específicos de ciertos ritmos.

### Pruebas de hipótesis

Se calcularon las pruebas de hipótesis para las arritmias SR y AF, lo que hacemos es plantear las hipótesis.

#### Hipótesis general

- Hipótesis nula ( $H_0$ ): No hay diferencia significativa en las características extraídas (DCT, FDT y MFCC) entre los grupos de arritmia SR y AF.
- Hipótesis alternativa ( $H_1$ ): Sí hay una diferencia significativa en las características extraídas (DCT, FDT y MFCC) entre los grupos SR y AF.

#### Shapiro-Wilk (normalidad)

- $H_0$  (hipótesis nula): Las distribuciones en los dos grupos SR y AF siguen una distribución normal.
- $H_1$  (hipótesis alternativa): Las distribuciones en los dos grupos SR y AF no siguen una distribución normal.

#### Prueba t de Student

(si las características siguen distribución normal)

- Hipótesis nula ( $H_0$ )

No hay diferencia significativa entre los vectores de características (DCT, FDT, MFCC) de los grupos de arritmia SR y AF.

- Hipótesis alternativa ( $H_1$ )

Sí hay diferencia significativa entre los vectores de características (DCT, FDT, MFCC) de los grupos SR y AF.

#### prueba de Mann-Whitney

- Hipótesis nula ( $H_0$ )

No hay diferencia significativa en las características (DCT, FDT, MFCC) entre los grupos SR y AF.

- Hipótesis alternativa ( $H_1$ )

Sí hay diferencia significativa en las características (DCT, FDT, MFCC) entre los grupos SR y AF.

Encontrando así los resultados aplicados a este par de arritmias en las figuras 22,23 y 24

```
Shapiro SR p=0.0000 -> No normal
Shapiro AF p=0.0000 -> No normal
Levene p=0.0000 -> Heterocedasticidad
Mann-Whitney U p=0.0000 -> Diferencia significativa
```

**Figura 22.** Pruebas de hipótesis en la DCT.

```
Shapiro SR p=0.0000 -> No normal
Shapiro AF p=0.0000 -> No normal
Levene p=0.0380 -> Heterocedasticidad
Mann-Whitney U p=0.0000 -> Diferencia significativa
```

**Figura 23.** Pruebas de hipótesis en la FDT.

```
Shapiro SR p=0.0000 -> No normal
Shapiro AF p=0.0000 -> No normal
Levene p=0.6120 -> Homocedasticidad
Mann-Whitney U p=0.9398 -> No hay diferencia significativa
```

**Figura 24.** Pruebas de hipótesis en la MFCC..

Lo que rechazamos la hipótesis general, ya que se puede encontrar diferencias entre los grupos los cuales en la prueba de MFCC sus coeficientes son parecidos en su nivel de energía, lo cual en el resto de transformadas se diferenciaron, lo que nos permite concluir que se logra diferenciar sus componentes en las transformadas DCT y FDT.

### IV. Discusión

Los resultados del presente trabajo evidencian que las transformadas DFT, DCT y MFCC aplicadas a señales ECG permiten extraer características espectrales relevantes para diferenciar entre distintos tipos de arritmias. A través de análisis descriptivos y pruebas de hipótesis, se observaron diferencias estadísticamente significativas en la distribución de la energía espectral y en los coeficientes extraídos, especialmente en las clases AF y SR. Este enfoque concuerda con estudios previos que destacan la utilidad del análisis espectral como herramienta diagnóstica en cardiología computacional.



El trabajo de Acharya et al. [7] resalta la importancia del análisis espectral combinado con métodos automáticos para la detección de arritmias. Aunque se centró en redes neuronales profundas, el proceso inicial de extracción de características incluyó transformadas en frecuencia. Ellos demostraron que patrones como la concentración energética en ciertas bandas espectrales son clave para identificar eventos cardíacos como la fibrilación auricular. De forma consistente, en este estudio se observó que las clases AF y AFIB presentan una menor potencia espectral, lo cual podría reflejar la pérdida de organización rítmica en el músculo auricular, generando señales más caóticas y con menor energía concentrada.

El trabajo de Tsipouras et al. [8] utiliza intervalos RR como base para clasificar arritmias, demostrando que incluso sin procesar la señal completa, el comportamiento espectral de los intervalos cardíacos revela información útil. Nuestro enfoque amplía esta idea al aplicar DCT sobre la autocorrelación de los picos R, encontrando que los primeros coeficientes contienen la mayor parte de la energía y permiten discriminar entre ritmos como SVT y SB. La potencia notablemente mayor en los coeficientes DCT de SVT podría asociarse con su naturaleza rápida y más organizada en comparación con otros tipos de arritmias.

Por otra parte, Moody y Mark [9], al desarrollar la base de datos MIT-BIH y evaluar algoritmos de detección automática, señalaron que la variabilidad de la señal ECG debe ser capturada con precisión en el tiempo y en frecuencia. En concordancia, el uso de MFCC en este estudio permitió observar cómo los coeficientes cepstrales reflejan cambios sutiles pero consistentes entre arritmias. Por ejemplo, el coeficiente 2 elevado en las clases ST y AF puede relacionarse con picos de energía más definidos en ciertas bandas del espectro Mel, lo cual es coherente con la respuesta de estos ritmos a eventos isquémicos o de despolarización auricular.

En conjunto, los resultados sugieren que no hay una única transformación superior, sino que cada técnica aporta una perspectiva complementaria. La DFT es útil para evaluar la distribución global de energía, la DCT comprime patrones clave y los MFCC permiten detectar características temporales y espectrales combinadas. Además, la validación

mediante pruebas de hipótesis (Shapiro-Wilk, t de Student, y Mann-Whitney) otorga rigor estadístico a la diferenciación entre grupos, reforzando que estas métricas no son producto del azar sino de variaciones fisiológicas reales.

Se demuestra en este estudio que la combinación de técnicas de procesamiento espectral y estadística aplicada no solo permite diferenciar entre tipos de arritmia, sino que establece una base sólida para futuros desarrollos de sistemas de diagnóstico automático basados en inteligencia artificial o aprendizaje automático, donde estas características podrían alimentar clasificadores más avanzados.

## V. Conclusiones

Las transformadas DFT, DCT y MFCC permiten extraer características espectrales efectivas para la diferenciación de arritmias: Cada técnica ofrece ventajas particulares; la DFT permite analizar la distribución global de energía en frecuencia, la DCT facilita la compresión y destaca patrones relevantes, y los MFCC capturan detalles espectrales temporales útiles para detectar irregularidades cardíacas.

Los análisis estadísticos aplicados (descriptivos y pruebas de hipótesis) confirmaron diferencias significativas entre tipos de arritmia, especialmente en coeficientes como MFCC<sub>0</sub>, DCT<sub>0</sub> y la potencia espectral promedio. Esto valida que los patrones extraídos no son aleatorios, sino que reflejan cambios en cómo se comportan las arritmias.

La integración del análisis espectral con técnicas estadísticas ofrece una base sólida para el desarrollo de herramientas automáticas de clasificación de arritmias, aportando un enfoque cuantitativo y reproducible que puede ser implementado en sistemas de ayuda diagnóstica.

## Referencias.

- [1] A. Hossen, M. M. Hassan, y M. Monirujjaman Khan, "Automated ECG Arrhythmia Classification Using Feature Images with Common Matrix Approach-Based Classifier," *Sensors*, vol. 25, no. 4, p. 1220, Feb. 2023.
- [2] M. I. Daud, A. Hussain, y M. M. Hasan, "Arrhythmia Classification Based on Multi-Domain Feature Extraction for an ECG Recognition System," *Sensors*, vol. 16, no. 10, p. 1744, Oct. 2016.
- [3] A. Abdelmaksoud, M. Elhoseny, y S. Ramalingam, "Deep Learning-Assisted Arrhythmia Classification Using 2-D ECG Spectrograms," *EURASIP Journal on*

Advances in Signal Processing, vol. 2024, no. 1, pp. 1–18, Jan. 2024.

- [4] H. Zhao et al., “Arrhythmia Classification and Diagnosis Based on ECG Signal: A Multi-Domain Collaborative Analysis and Decision Approach,” *Electronics*, vol. 11, no. 19, p. 3251, Oct. 2022.
- [8] X. Liu et al., “Spectrogram-Based Arrhythmia Classification Using Three-Channel Deep Learning Model with Feature Fusion,” *Applied Sciences*, vol. 14, no. 21, p. 9936, Nov. 2023.
- [5] H. Y. Kim y H. J. Kim, “Classification of Arrhythmia by Using Deep Learning with 2-D ECG Spectral Image Representation,” *arXiv preprint, arXiv:2005.06902*, May 2020.
- [6] A. K. Singh and S. Krishnan, “ECG signal feature extraction trends in methods and applications,” *BioMedical Engineering OnLine*, vol. 22, no. 1, Mar. 2023, doi: <https://doi.org/10.1186/s12938-023-01075-1>.
- [7] U. R. Acharya, H. Fujita, S. L. Oh, Y. Hagiwara, J. H. Tan y M. Adam, "Application of deep convolutional neural network for automated detection of myocardial infarction using ECG signals," *Information Sciences*, vol. 415–416, pp. 190–198, 2017.
- [8] M. G. Tsipouras, D. I. Fotiadis y D. K. Sideris, "An arrhythmia classification system based on the RR-interval signal," *Artificial Intelligence in Medicine*, vol. 33, no. 3, pp. 237–250, 2005.
- [9] G. B. Moody y R. G. Mark, "The impact of the MIT-BIH Arrhythmia Database," *IEEE Engineering in Medicine and Biology Magazine*, vol. 20, no. 3, pp. 45–50, 2001.